KAIST Korea Advanced Institute of Science and Technology

Clustering
(K-means Clustering)

Jeonghun Yoon

What is Clustering?

2000년과 2004년도 미국 대통령 선거는 정말 치열했다.

가장 많은 표를 얻은 후보는 전체 득표의 50.7%를 차지했고, 가장 적은 표를 얻은 후보는 전체 득표의 47.9%를 차지했다. 만약 1.4%의 투표자가 자신의 표를 바꾸었다면, 투표 결과는 완전히 달라졌을 것이다. 전체 인구에서 특정 후보를 강력하게 지지하지 않고, 단지 선거 유세를 통해 마음을 바꿀 수 있는 1.4%의 사람들만 찾았으면 말이다...

만약 이 소수의 투표자 그룹의 마음을 돌렸다면, 특히 이렇게 치열한 레이스에서, 미국 대통령은 달라졌을 수 있다.

여기서, 우리는 전체 집단을 몇 개의 그룹을 나누는 문제를 생각해 볼 수 있다.

즉, 투표자들 전체 집단을 어떤 기준에 따라 그룹을 나누는 것이다.
그리고 각각의 그룹에 특성화 된 선거 전략을 세우는 것이다.

What is Clustering?

그러면 어떻게 그룹을 나눌까?

먼저, 미국 투표자들 개개인의 정보를 얻는다. 이 정보는 그들이 투표를 하는 데에 영향을 미칠 수 있는 요소가 무엇인지에 대한 단서를 얻을 수 있는 중요한 것들일 수 있다.

feature

다음으로 이 정보들을 가지고 그룹(clusters)을 나눈다.

clustering

그러면, 특정 정당과 후보를 지지하는 그룹, 정당과 후보 보다는 공약에 좌우되는 그룹, 주변의 분위기에 편승되는 그룹 등등 그룹들을 찾을 수 있다.

그리고 각 그룹에 맞는, 즉 각 그룹의 유권자들에 특화된, 선거 유세를 그룹별로 진행한다.

KAIST

What is Clustering?

What is natural grouping among these objects?

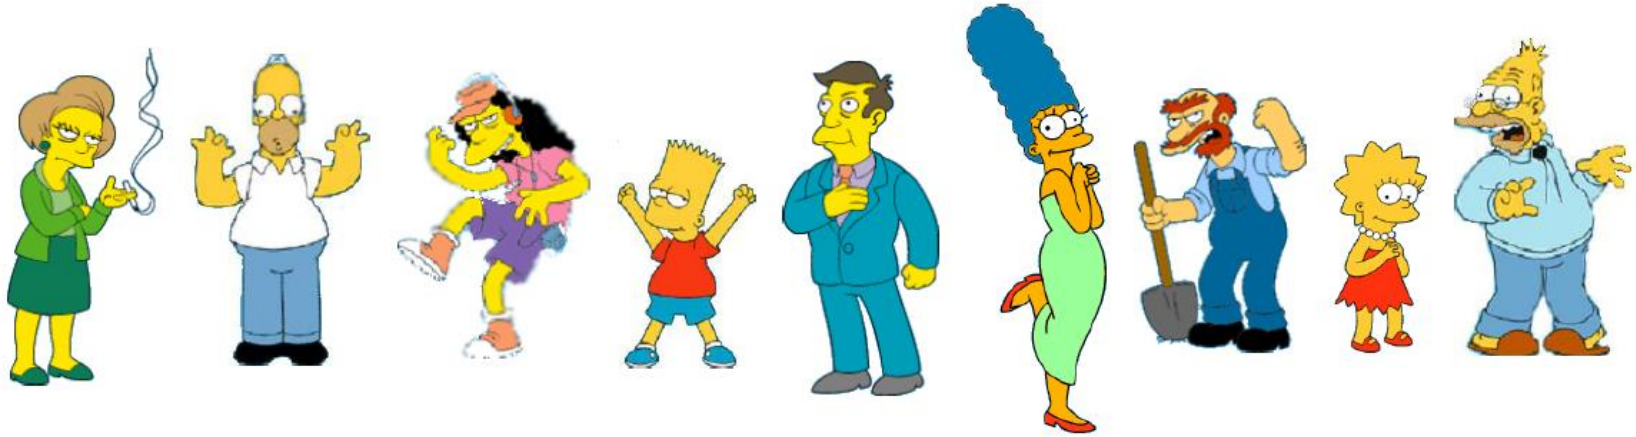

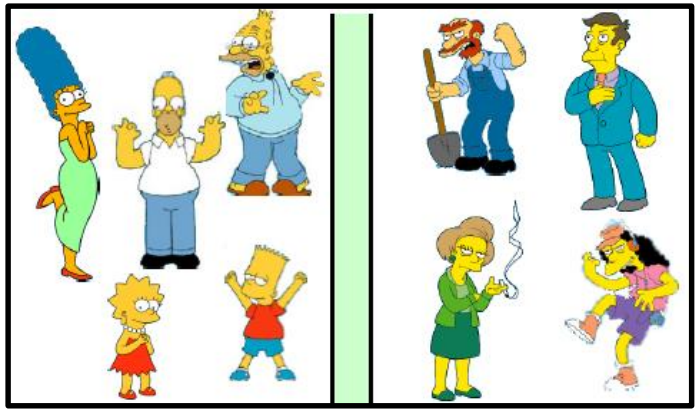

Simpson's Family

None Simpson's Family
(School Employees)

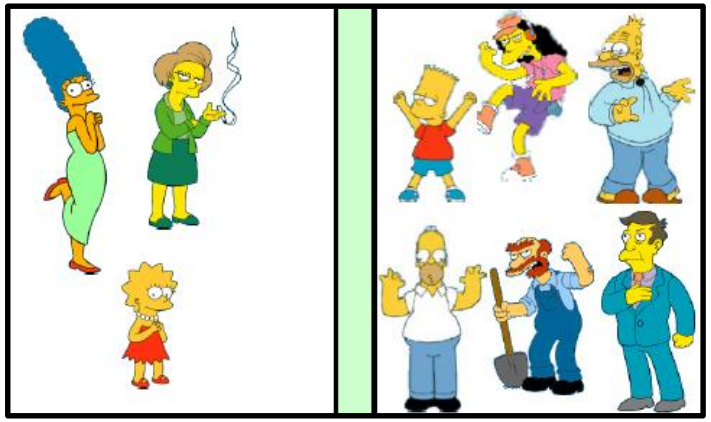

Females

males

KAIST

What is Clustering?

Original Image

2 colors

4 colors

8 colors

What is Clustering?

- What is Clustering?

  ○ Organizing data into clusters such that there is
  ① high intra-cluster similarity
  ② low inter-cluster similarity

  ○ Informally, finding natural grouping among object.

- Clustering 이란?

  ○ data를 다음의 두 가지 조건을 만족하는 cluster(군집, 집단)로 조직(organizing)
  ① cluster 내부의 data들 간의 similarity(유사성)이 높다.
  ② cluster 외부의 data들 간의 similarity(유사성)이 낮다.
  ※ 유사성이 무엇일까?

What is Clustering?

What is natural grouping among these objects?

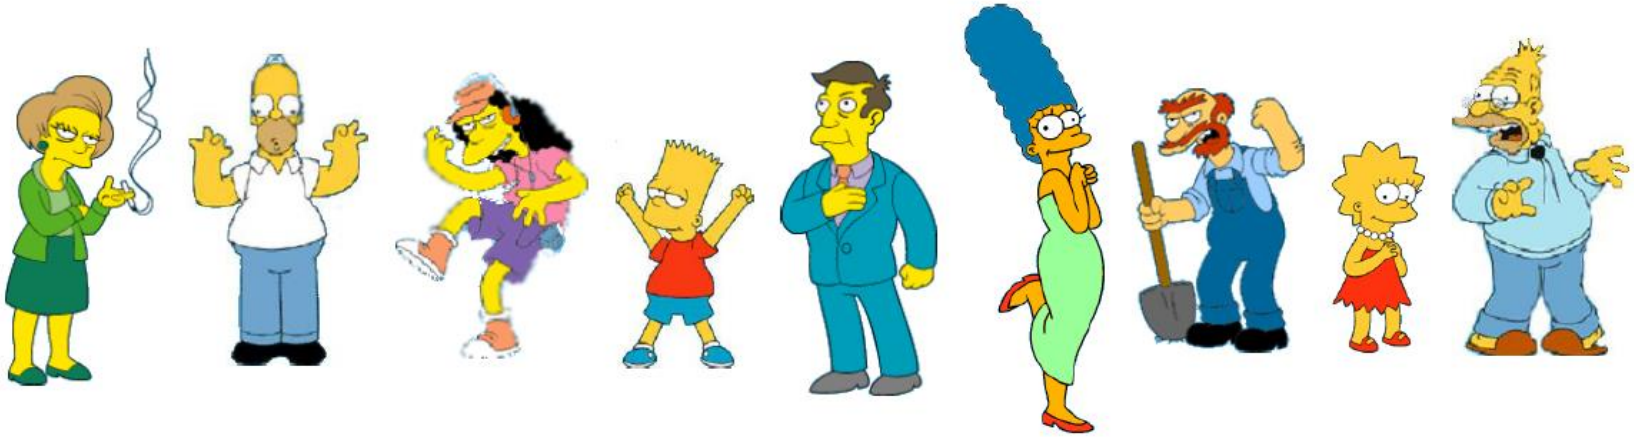

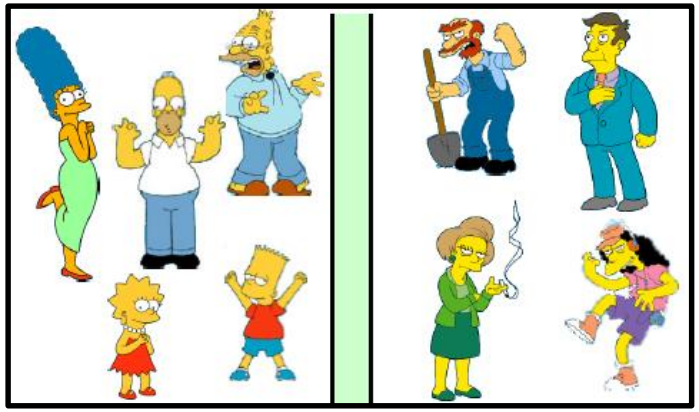

Simpson's Family

None Simpson's Family
(School Employees)

similarity : 이름

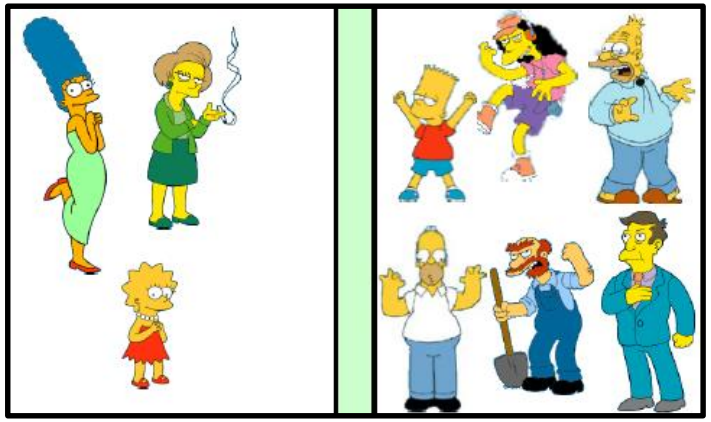

Females

males

similarity : 하의(치마, 바지)
눈썹

KAIST

- What is **Similarity**?
  - The quality or state of being similar; likeness; resemblance; as a similarity of feature. (Webster's Dictionary)
  - similarity(유사성)은 정의하기 힘드나, 우리는 그것을 눈으로 보면 직관적으로 안다.
  - similarity의 실제 의미는 철학적인 문제이다.

비슷한가요??

유사한가요??

- 두 개의 object사이의 similarity를 측정하기 위해서 두 object 사이의 거리 (distance , dissimilarity)를 측정한다.

- 아래 그림의 두 object 사이의 거리는 어떻게 측정할까?

  - object 사이의 거리를 재기 위해서는, objects을 거리를 잴 수 있는 공간의 데이터들로 mapping 시켜야 된다.
  - Patty와 Selma의 거리를 재기 위해서는, 예를 들어, 사람이라는 objects을 (입은 옷, 귀고리, 머리 모양, 몸무게, 키, 흡연)의 특성 벡터로 표현 될 수 있는 데이터로 mapping 하는 것이다.

데이터를 유클리디안 공간의 점으로 변환

- 거리(Distance)란?

  - Edit Distance (두 개의 objects 사이의 similarity를 측정하는 일반적인 기법)

    ① 한 개의 object에서, 다른 한 개의 object으로 변화되기 위하여 필요한 노력 (effort)를 측정한다.

The distance between Patty and Selma
- Change dress color, 1 point
- Change earning shape, 1 point
- Change hair part, 1 Point

D(Patty, Selma)=3

The distance between Marge and Selma
- Change dress color, 1 point
- Add earning, 1 point
- Decrease height, 1 point
- Take up smoking, 1 point
- Lose weight, 1 point

D(Patty, Selma)=5

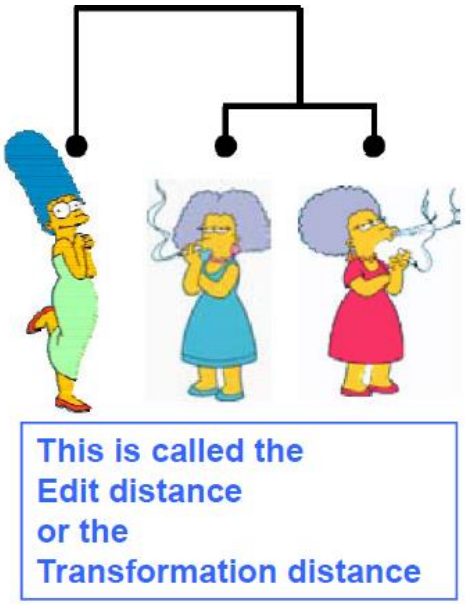

○ 거리(Distance)의 수학적인 개념

① O_1과 O_2를 두 개의 object이라고 할 때, O_1과 O_2 사이의 distance는 실수(real number)이고 $\boldsymbol{D(O_1, O_2)}$라고 표기

② 주의할 것! distance는 우리가 고등학교 때 배워서 알고 있는 유클리드 거리만 의미하는 것이 아니다. distance function은 다양하게 설정할 수 있다.

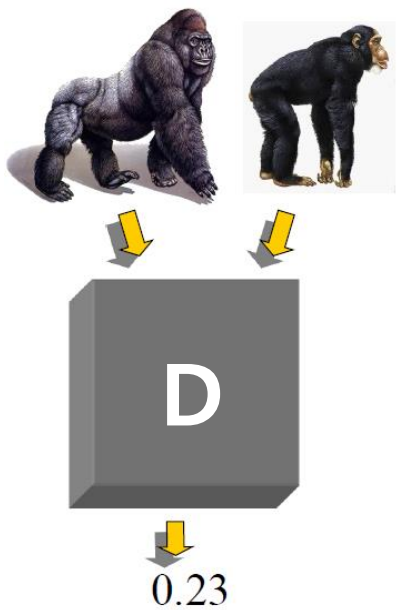

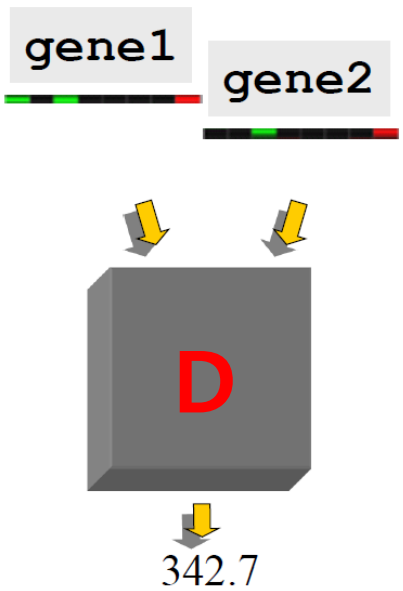

○ Distance function 과 Similarity function의 예

$\mathbb{x} = (x_1, x_2, \dots)$, $\mathbb{y} = (y_1, y_2, \dots)$ 라고 하자.

① Euclidian distance (dissimilarity)

$$D(\mathbb{x}, \mathbb{y}) = d(\mathbb{x}, \mathbb{y}) = \sqrt{\sum_i (x_i - y_i)^2}$$

② Manhattan distance (dissimilarity)

$$D(\mathbb{x}, \mathbb{y}) = d(\mathbb{x}, \mathbb{y}) = \sum_i |x_i - y_i|$$

③ "sup" distance (dissimilarity)

$$D(\mathbb{x}, \mathbb{y}) = d(\mathbb{x}, \mathbb{y}) = \max_i |x_i - y_i|$$

④ Correlation coefficient (similarity)

$$D(\mathbb{x}, \mathbb{y}) = s(\mathbb{x}, \mathbb{y}) = \frac{\sum_i (x_i - \mu_{\mathbb{x}})(y_i - \mu_{\mathbb{y}})}{\sigma_x \sigma_y}$$

⑤ Cosine similarity (similarity)

$$D(\mathbb{x}, \mathbb{y}) = \cos(\mathbb{x}, \mathbb{y}) = \frac{\mathbb{x} \cdot \mathbb{y}}{\|\mathbb{x}\| \|\mathbb{y}\|} = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2} \sqrt{\sum_i y_i^2}}$$

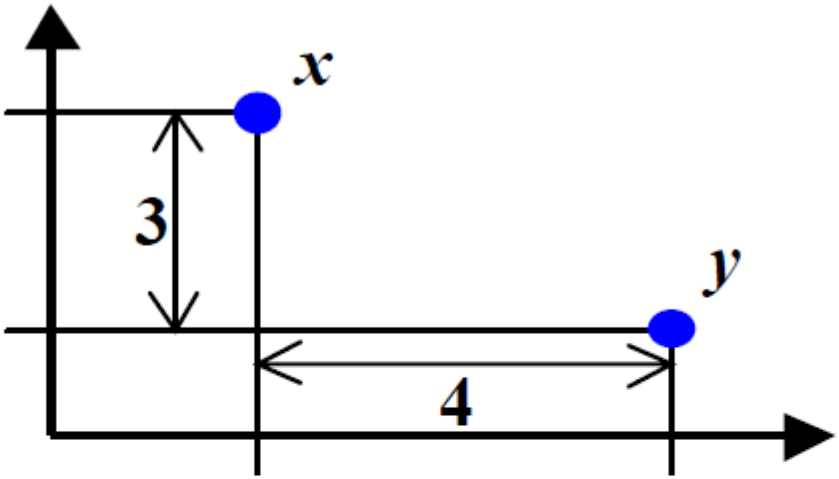

1 : Euclidean distance : $\sqrt[2]{4^2+3^2}=5.$

2 : Manhattan distance : $4+3=7.$

3 : "sup" distance : $\max\{4,3\}=4.$

What is Clustering?

- Why Clustering

  - data를 cluster(군집)들로 조직하면(organizing), data의 내부 구조(internal structure)에 대한 정보를 얻을 수 있음

  - data를 분할하는 것(partitioning) 자체가 목적이 될 수 있음
    ① 이미지 분할(image segmentation)

  - data에서 지식을 발견하는 것이 목적이 될 수 있음 (knowledge discovery in data)
    ① Underlying rules
    ② topic

What is Clustering?

- What is the clustering problem?

  - Input
    ① Training set $\boldsymbol{S_n} = \{\mathbb{x}^{(\boldsymbol{i})}, \boldsymbol{i} = \boldsymbol{1}, \dots, \boldsymbol{n}\}$, where $\mathbb{x}^{(i)} \in R^d$
    ② Integer $\boldsymbol{k}$

  - Output
    ① A set of clusters $\boldsymbol{C_1}, \boldsymbol{C_2}, \dots, \boldsymbol{C_k}$

$$\mathbb{x}^{(1)} = \left\{x_1^{(1)}, x_2^{(1)}, \dots, x_d^{(1)}\right\}$$
$$\mathbb{x}^{(2)} = \left\{x_1^{(2)}, x_2^{(2)}, \dots, x_d^{(2)}\right\}$$
$$\dots$$
$$\mathbb{x}^{(n)} = \left\{x_1^{(n)}, x_2^{(n)}, \dots, x_d^{(n)}\right\}$$

Clustering

$$C_1 = \{\mathbb{x}^{(1)}, \mathbb{x}^{(4)} \dots\}$$
$$C_2 = \{\mathbb{x}^{(2)}, \mathbb{x}^{(6)} \dots\}$$
$$\dots$$
$$C_k = \{\mathbb{x}^{(3)}, \mathbb{x}^{(8)} \dots\}$$

K-Means Clustering

What is K-means clustering?

같은 cluster에 속하는 데이터들의 inner similarity를 증가시키는 방향으로 cluster를 형성

가정 : 데이터가 유클리디안 공간위에 있어야 한다.
(평균을 구할 수 있도록, 실수의 좌표를 가져야 한다.)

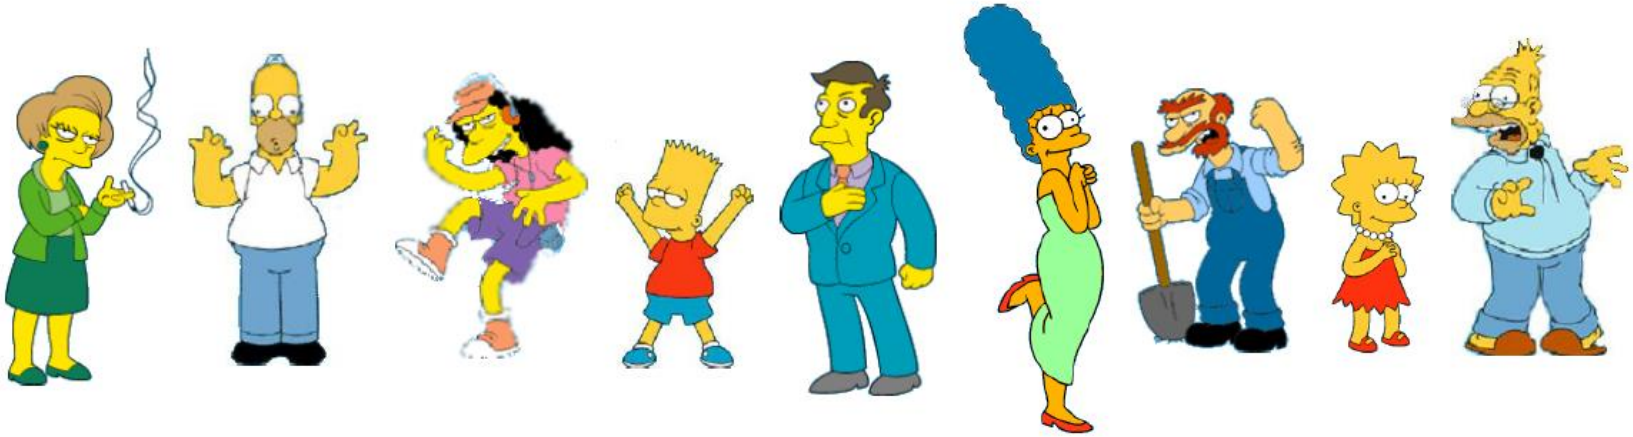

(1,2) (2,2) (4,10) .....

What is K-means clustering?

K-means clustering

① cluster의 개수를 3개로 정함

② K개의 초기 centroid(클러스터의 중심이 될)를 random하게 선택한다.

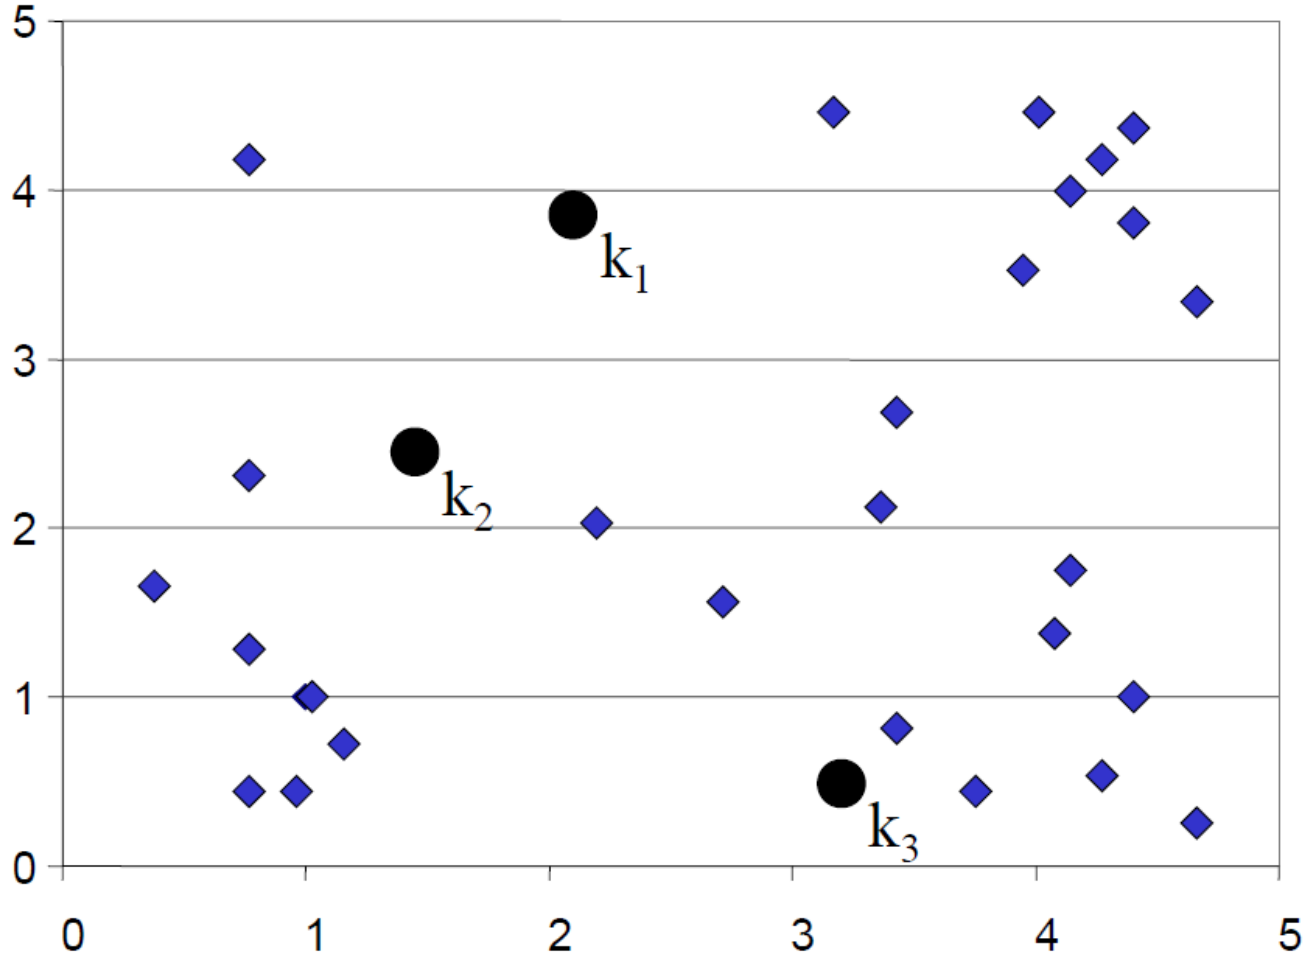

What is K-means clustering?

K-means clustering

① 각각의 object을, 자기자신에게서 가장 가까운 centroid k_i에 할당한다.

② 같은 centroid에 할당된 object들의 평균을 구한다.

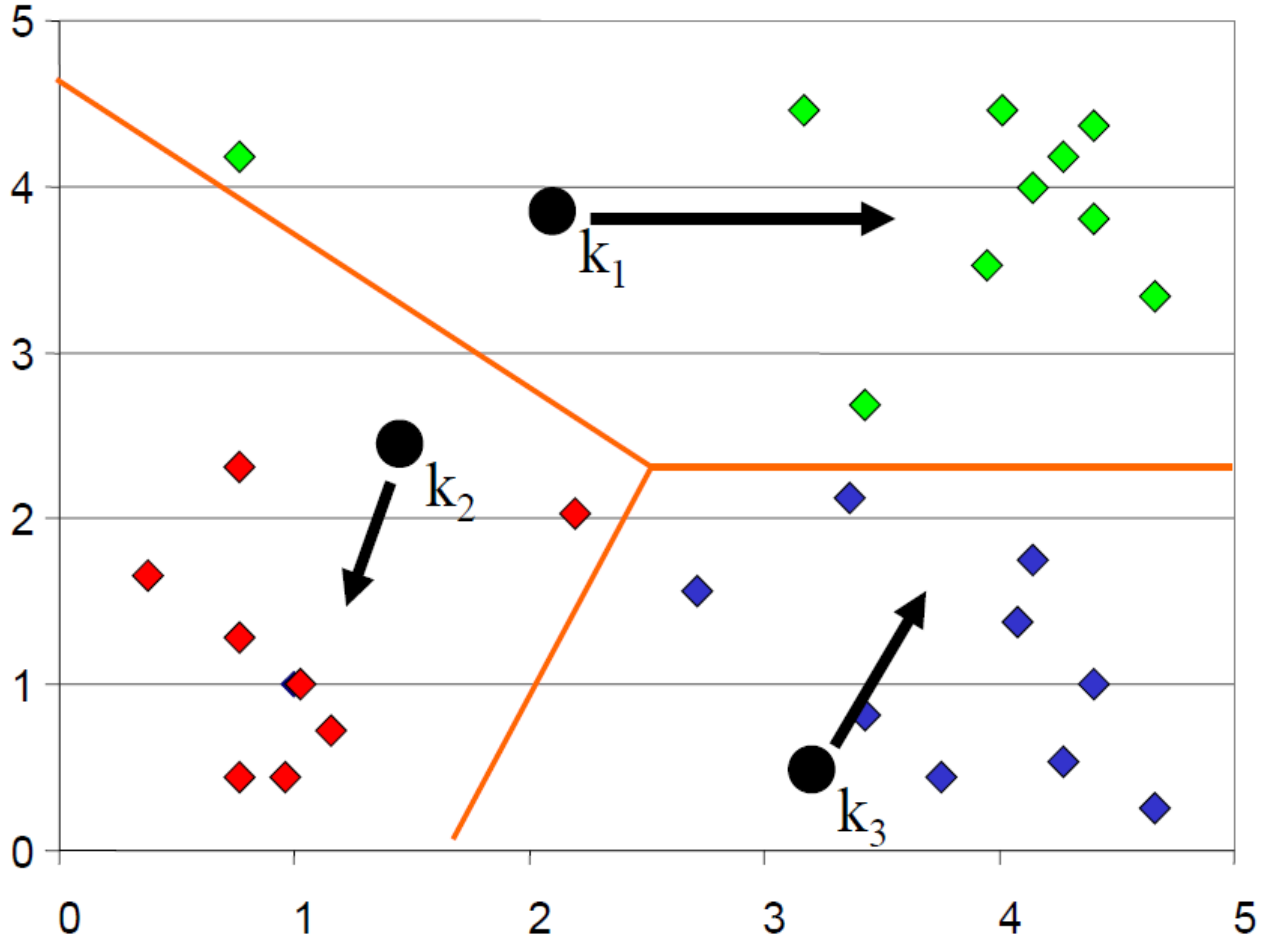

K-means clustering

① 구한 평균값을 2번째 centroid 값으로(클러스터의 중심으로) 설정한다.

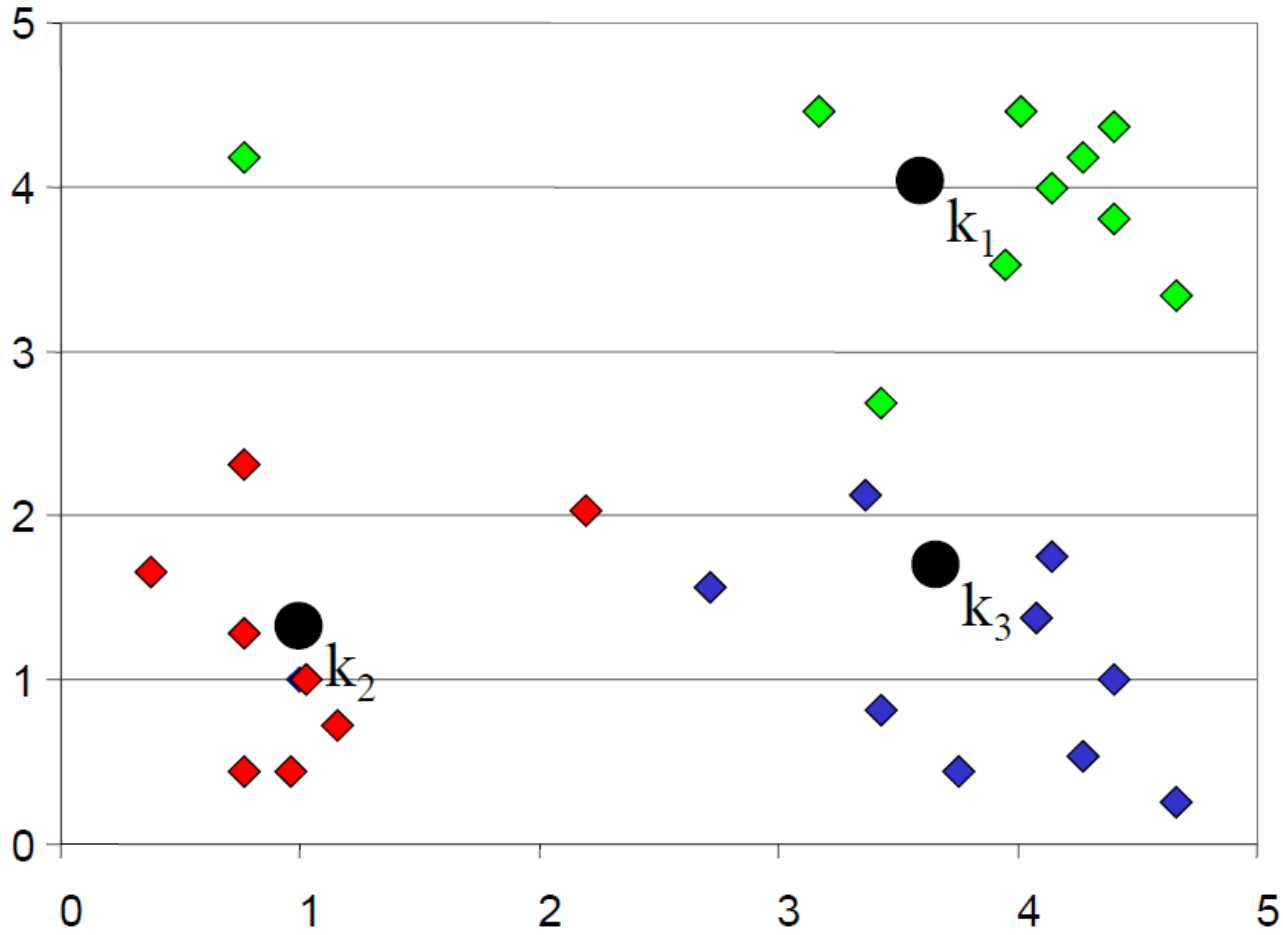

K-means clustering

① 각각의 object을, 자기자신에게서 가장 가까운 centroid k_i에 할당한다. (2번째 centroid)

② 같은 centroid에 할당된 object들의 평균을 구한다.

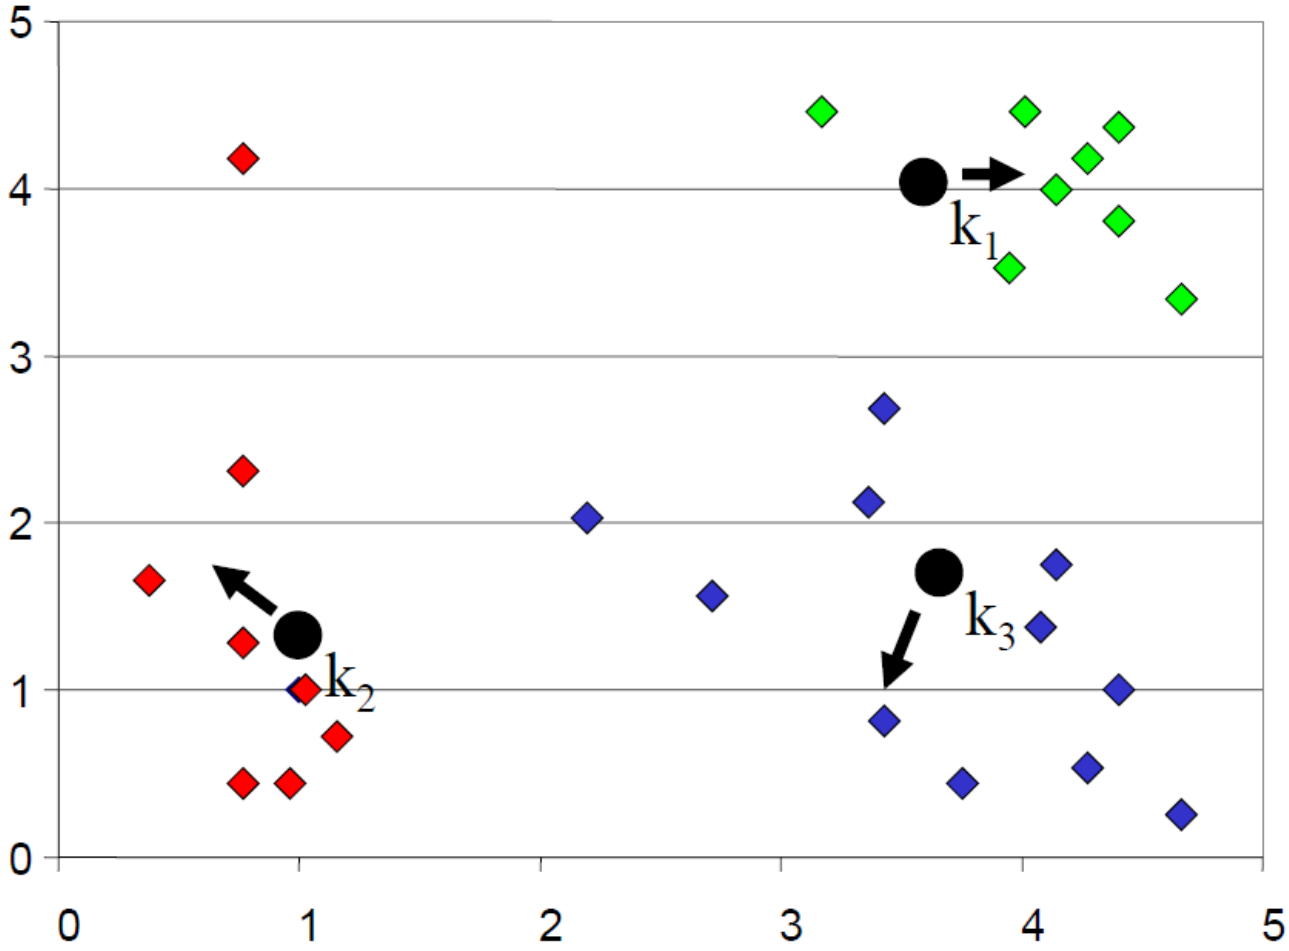

K-means clustering

① 구한 평균값을 3번째 centroid 값으로(클러스터의 중심으로) 설정한다.

② 각각의 object을, 자기자신에서 가장 가까운 centroid k_i에 할당한다. (3번째 centroid)

③ 각각의 centroid에 할당된 object들의 멤버쉽이 변화가 없을 때까지 반복한다.

더 이상, 데이터 자신이 속한 클러스터가 변하지 않는 것을 의미한다.

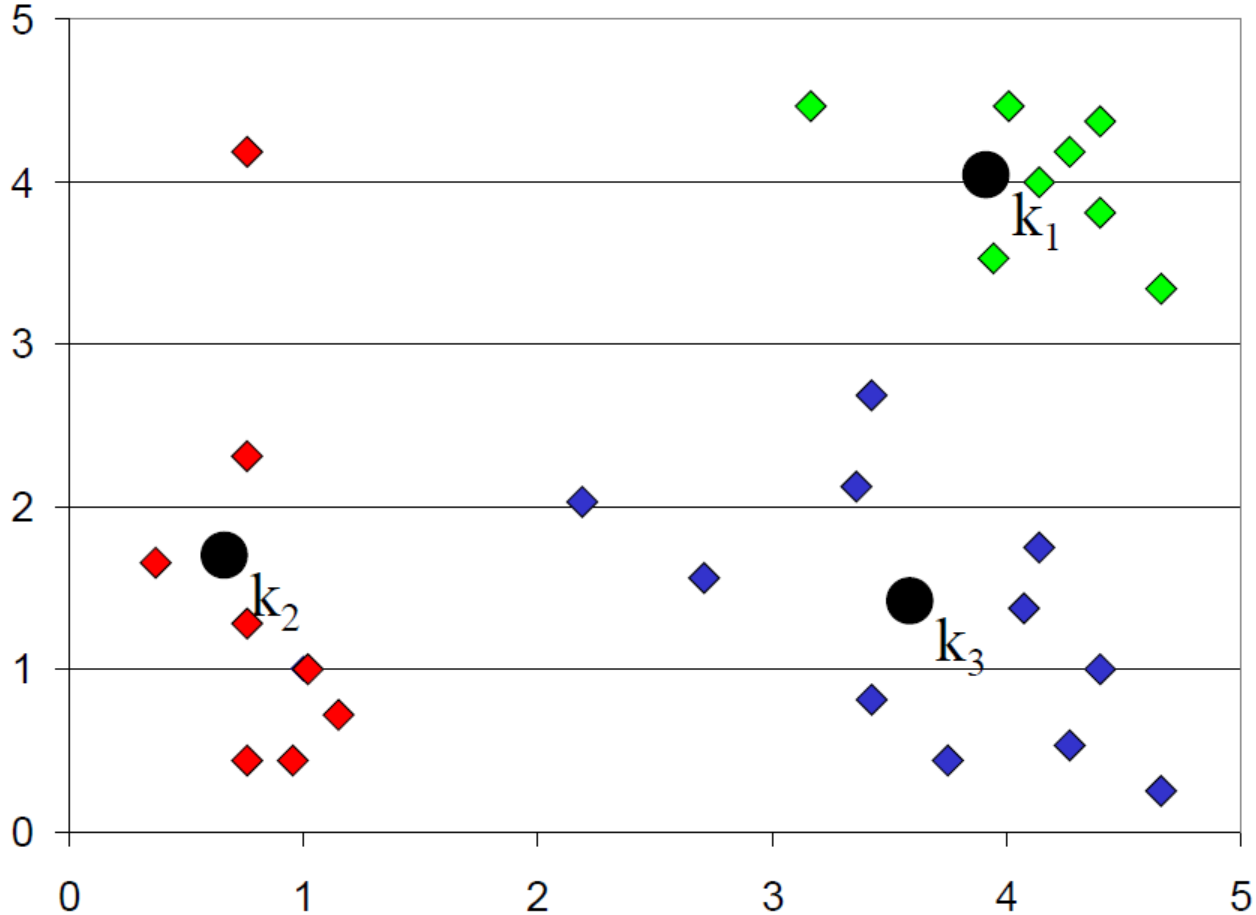

What is K-means clustering?

- Algorithm
  - K의 값을 결정한다. K는 cluster의 개수이다.
  - K cluster의 초기 centroid $\mathbb{C} = \{\mathbb{c}^{(1)}, \mathbb{c}^{(2)}, \dots, \mathbb{c}^{(K)})$를 random하게 설정한다.
  - 각각의 object을, 그 object과 가장 가까운 centroid로 할당한다. 이것을 통해 전체 object의 class membership을 결정한다.
  - 같은 centroid에 할당된 object들의 평균값 $\boldsymbol{\mu} = \{\mathbb{m}^{(1)}, \mathbb{m}^{(2)}, \dots, \mathbb{m}^{(K)}\}$을 구한다.
  - 구한 평균값을 새로운 centroid로 설정. $\mathbb{C} = \{\mathbb{c}^{(1)}, \mathbb{c}^{(2)}, .., \mathbb{c}^{(K)}) \leftarrow \boldsymbol{\mu} = \{\mathbb{m}^{(1)}, \mathbb{m}^{(2)}, .., \mathbb{m}^{(K)}\}$
  - 하늘색의 단계를, 더 이상 어떠한 object도 자신이 속한 cluster가 변하지 않을 때까지, 즉 cluster의 membership이 바뀌지 않을 때까지 반복한다.

    더 이상, 데이터 자신이 속한 클러스터가 변하지 않는 것을 의미한다.

※ 수학적인 표기

- Clusters based on centroid

$$C_j = \{i \mid i \in \{1, \dots, n\}\ s.t.\ the\ closest\ centroid\ from\ \mathbb{x}^{(i)}\ is\ \mathbb{c}^{(j)}\}$$

  - C_j는 인덱스의 집합

- Cost function based on centroids

$$cost\left(C_1, C_2, \dots, C_K, \mathbb{c}^{(1)}, \mathbb{c}^{(2)}, \dots, \mathbb{c}^{(K)}\right) = \sum_{j=1,\dots,K} \sum_{i \in C_j} \left\| \mathbb{x}^{(i)} - \mathbb{c}^{(j)} \right\|$$

What is K-means clustering?

Mathematical description

- Algorithm(mathematical notation)
  - Initialize centroids $\mathbb{c}^{(1)}, \mathbb{c}^{(2)}, \dots, \mathbb{c}^{(K)}$
  - Repeat until there is no further change in $cost\left(C_1, C_2, \dots, C_K, \mathbb{c}^{(1)}, \mathbb{c}^{(2)}, \dots, \mathbb{c}^{(K)}\right)$

    ① for each $j = 1, \dots, K$: $C_j = \{i \mid i\ s.t.\ \mathbb{x}^{(i)}\ is\ closest\ to\ \mathbb{c}^{(j)}\}$

    ② for each $j = 1, \dots, K$: $\mathbb{c}^{(j)} = \frac{1}{|C_j|} \sum_{i \in C_j} \mathbb{x}^{(i)}$

- K-means clustering 알고리즘은 수렴하는가?

  - 그렇다. 알고리즘의 ①, ②번 스텝에서 cost function의 값이 줄어든다. 따라서 전체 알고리즘에서의 cost 값은 점진적으로(monotonically) 감소한다.

  - Step ① : reassigning clusters based on distance

    Old clusters : $C_1^o, C_2^o, \dots, C_K^o$

    New clusters : $C_1^N, C_2^N, \dots, C_K^N$

$$cost(C_1^o, C_2^o, \dots, C_K^o, \mathbb{c}_1, \mathbb{c}_2, \dots, \mathbb{c}_K) \geq \min_{C_1,\dots,C_K} cost(C_1, C_2, \dots, C_K, \mathbb{c}_1, \mathbb{c}_2, \dots, \mathbb{c}_K)$$

$$\overset{①}{=} cost(C_1^N, C_2^N, \dots, C_K^N, \mathbb{c}_1, \mathbb{c}_2, \dots, \mathbb{c}_K)$$

- K-means clustering 알고리즘은 수렴하는가?

  - 그렇다. 알고리즘의 ①, ②번 스텝에서 cost function의 값이 줄어든다. 따라서 전체 알고리즘에서의 cost 값은 점진적으로(monotonically) 감소한다.

  - Step ② : reassigning centroids based on clusters

    Old centroid : $\mathbb{c}_1, \mathbb{c}_2, \dots, \mathbb{c}_K$

    New centroid : $\mathbb{c}_1^N, \mathbb{c}_2^N, \dots, \mathbb{c}_K^N$

$$cost(C_1^N, C_2^N, \dots, C_K^N, \mathbb{c}_1, \mathbb{c}_2, \dots, \mathbb{c}_K) \geq \min_{\mathbb{c}, \dots, \mathbb{c}_K} cost(C_1^N, C_2^N, \dots, C_K^N, \mathbb{c}_1, \mathbb{c}_2, \dots, \mathbb{c}_K)$$

$$\overset{②}{=} cost(C_1^N, C_2^N, \dots, C_K^N, \mathbb{c}_1^N, \mathbb{c}_2^N, \dots, \mathbb{c}_K^N)$$

What is K-means clustering?

- Strength
  - Simple, easy to implement and debug
  - Intuitive objective function : optimize intra-cluster similarity
  - Relatively efficient : $O(tkn)$, where n is number of objects, k is number of clusters and n is number of iterations. Normally, k, $t \ll n$.
- Weakness
  - Applicable only when mean is defined. → **k-medoids**
  - Often terminates at a local optimum. Initialization is important.

    → Not suitable to discover clusters with non-convex shapes
  - Need to specify K, the number of clusters, in advance.
  - Unable to handle noisy data and outliers → **k-medoids**
- Summary
  - Assign members based on current centers
  - Re-estimate centers based on current assignment

What is K-means clustering?

Global/ Local optimum

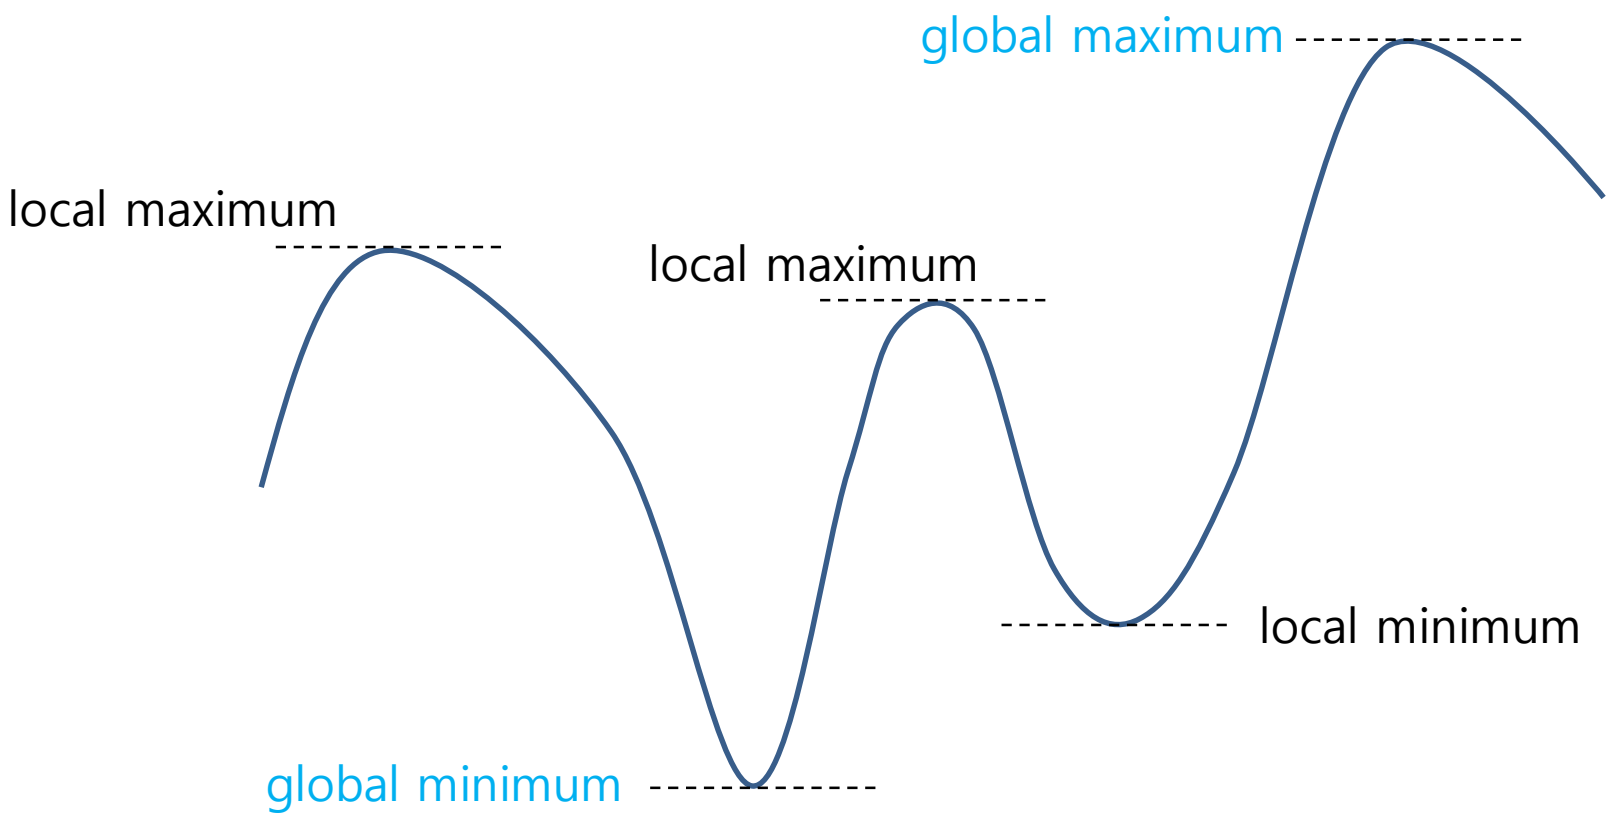

Convex function : local optimum = global optimum
ex) 2차 함수

그러면 K-means는 local optimum에 빠질 수 있는데 어떻게 해야 하나?
초기값을 바꾸면서 여러 번 반복한다. 그리고 반복 된 값 중에서 비용함수가 가장 작은 값을 선택한다.

K-medoids

- K-means 알고리즘에서, cluster의 중심에 외톨이(outlier)가 배정되어 있다면, 이 outlier도 평균 계산에 참여하니까 새로운 군집 중심이 왜곡될 것이다.
- 이러한 왜곡을 완화시켜주는 역할을 하는 것이 K-medoids이다.
- 샘플의 평균이 아닌, 샘플들 중에서 대표 샘플을 찾는다.
  - 다른 샘플들까지의 거리의 합이 최소가 되는 샘플을 대표 샘플로 지정한다.

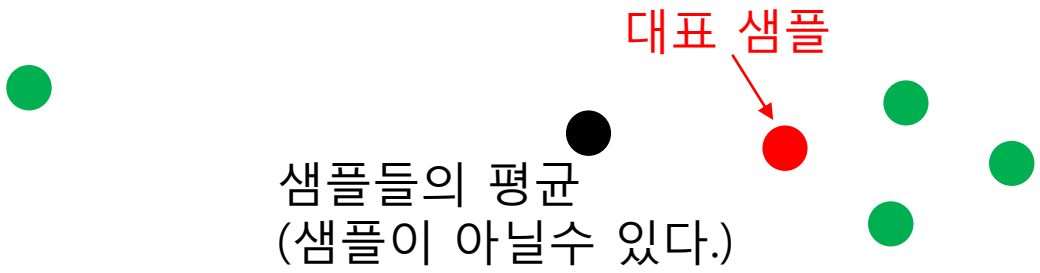

How to select K?

- $X = \{x_1, \dots, x_n\}$라고 하면,

- 보통 집합 X에 속한 <u>샘플 중에 k개를 선정하여 초기화</u> 한다.

- <u>Sequential(순차) 알고리즘을 수행</u>하여 개략적인 cluster의 해를 만들고, 각 군집에서 대표를 하나씩 뽑아서 사용할 수도 있다.
  - 순차 알고리즘
    - ① 한 개의 cluster를 가지고 시작
    - ② 집합 X에 속한 모든 점에 대하여, 가장 가까운 cluster를 찾는다.
      - $\underline{D(x_i, c_q) = \min_{1 \le j \le m} D(x_i, c_j)}$
      - $D(x_i, c_q) > T$: 다른 cluster를 생성한다.
      - $D(x_i, c_q) < T$: 설정한 임계치보다 작으니깐 해당 클러스터에 넣는다.
  - 순차 알고리즘의 특징
    - ① k를 자동으로 찾아준다.
    - ② 임계 값 T를 입력값으로 넣어줘야 하는데, 적절한 값을 추정하기가 쉽지 않다.
    - ③ 샘플을 처리하는 순서에 따라 결과가 달라진다. (order dependent)

KAIST

Example

Subject	A	B
1	1.0	1.0
2	1.5	2.0
3	3.0	4.0
4	5.0	7.0
5	3.5	5.0
6	4.5	5.0
7	3.5	4.5

Goal : 2개의 클러스터로 나누고 싶다.

	Individual	Mean Vector (centroid)
Group 1	1	(1.0, 1.0)
Group 2	4	(5.0, 7.0)

1. Initial centroid 설정

	Cluster 1		Cluster 2	
Step	Individual	Mean Vector (centroid)	Individual	Mean Vector (centroid)
1	1	(1.0, 1.0)	4	(5.0, 7.0)
2	1, 2	(1.2, 1.5)	4	(5.0, 7.0)
3	1, 2, 3	(1.8, 2.3)	4	(5.0, 7.0)
4	1, 2, 3	(1.8, 2.3)	4, 5	(4.2, 6.0)
5	1, 2, 3	(1.8, 2.3)	4, 5, 6	(4.3, 5.7)
6	1, 2, 3	(1.8, 2.3)	4, 5, 6, 7	(4.1, 5.4)

2. 각각의 데이터를, 그 자신에게서 가장 가까운 centroid로 할당한다.

3. 동시에 각 cluster에 속한 데이터의 평균값을 구한다.

Example

Individual	Distance to mean (centroid) of Cluster 1	Distance to mean (centroid) of Cluster 2
1	1.5	5.4
2	0.4	4.3
3	2.1	1.8
4	5.7	1.8
5	3.2	0.7
6	3.8	0.6
7	2.8	1.1

4. 구한 평균값을 새로운 centroid로 한다.
   각각의 데이터에서, 모든 centroid까지의 거리들을 구한다.

	Individual	Mean Vector (centroid)
Cluster 1	1, 2	(1.3, 1.5)
Cluster 2	3, 4, 5, 6, 7	(3.9, 5.1)

5. 각각의 데이터를 그 데이터에게서 가장 가까운 centroid로 할당한다.

reference

- http://www.cs.cmu.edu/~10701/lecture/clustering.pdf
- http://www.cs.cmu.edu/~epxing/Class/10701/Lecture/lecture10-clustering.pdf
- http://cs229.stanford.edu/notes/cs229-notes7a.pdf